

Energy Efficiency Analysis

건축 특성이 난방·냉방 부하에 미치는 영향
기초통계 기반 분석 및 선형회귀 모델링

조 : 4조

조원 : 김근홍 · 박연제 · 손수경 · 이설현 · 이정인

과정명 : 데이터 분석 개요 및 기초통계

제출일 : 2026. 07. 28

SUMMARY

1. 건물 특성 — 에너지 효율 간 특징 및 관계

1-1. 데이터셋 개요

1-2. 중심화 · 퍼짐 · 분포

1-3. 시각화로 확인한 구조적 특징

2. EDA 기반 유효 변수 선별

2-1. 상관관계 및 다중공선성 그룹

2-2. 타깃과의 상관관계

2-3. 최종 변수 선택 원칙과 결과

3. 모델링 결과 및 해석

3-1. 회귀계수 및 성능 지표

3-2. 잔차 진단 (회귀 가정 검토)

4. 종합 결론 및 분석 제약사항

SUMMARY

본 프로젝트는 건축 특성 데이터(UCI Energy Efficiency Dataset, 768개 건물, X1~X8 8개 특성)를 이용해 난방 부하(Y1)·냉방 부하(Y2)에 영향을 미치는 요인을 기초통계로 분석하고, 이를 근거로 변수를 선별해 Y1·Y2 각각 독립적인 선형회귀 모델을 개발했다.

기술통계·시각화 결과 건물 높이(X5)는 사실상 두 값(3.5, 7.0)만 갖는 이진적 변수였고, 이로 인해 Y1·Y2 모두 이봉(bimodal) 분포를 보였다. 상관관계 분석에서는 상대적 집약도(X1)·표면적(X2)·지붕면적(X4)·높이(X5)가 서로 강하게 얽힌 다중공선성 그룹을 이루는 것을 확인했다. 상관관계만으로 변수를 선별하지 않는다는 원칙에 따라 이 그룹에서는 타깃 상관이 가장 큰 X5만 대표로 남기고, 다중공선성이 없는 나머지 변수(X3, X6, X7, X8)는 그대로 유지해 최종적으로 5개 변수를 선택했다.

이 변수들로 학습한 선형회귀 모델은 Y1 $R^2=0.904$, Y2 $R^2=0.882$ 의 설명력을 보였으며, 건물 높이(X5)와 유리창 면적(X7)의 영향력이 가장 크게 나타나 도메인 상식과 부합했다. 다만 잔차 진단 결과 건물 높이의 이진적 특성으로 인한 군집 패턴이 남아 있어 등분산성·정규성 가정이 완전히 충족되지는 않았음을 확인했다.

1. 건물 특성 — 에너지 효율 간 특징 및 관계

1-1. 데이터셋 개요

건물의 형태·면적·유리창 구성 등 8개 건축 특성(X1~X8)과, 이를 통해 결정되는 난방 부하 Y1(Heating Load)·냉방 부하 Y2(Cooling Load)로 구성된 768개 건물 케이스 데이터셋이다. 12개의 기본 건물 형태를 바탕으로 Ecotect 시뮬레이션을 통해 생성되었으며, 결측치는 없다.

변수	설명	타입
X1	Relative Compactness (상대적 집약도)	Continuous
X2	Surface Area (표면적)	Continuous
X3	Wall Area (벽 면적)	Continuous
X4	Roof Area (지붕 면적)	Continuous
X5	Overall Height (전체 높이)	Continuous(실질적 이진)
X6	Orientation (방향)	Integer(범주형 성격)
X7	Glazing Area (유리창 면적)	Continuous
X8	Glazing Area Distribution (유리창 면적 분포)	Integer(범주형 성격)
Y1	Heating Load (난방 부하) — 타깃	Continuous
Y2	Cooling Load (냉방 부하) — 타깃	Continuous

1-2. 중심화 · 퍼짐 · 분포

대부분의 변수는 평균과 중앙값의 차이가 크지 않아 극단적인 비대칭은 없다. 다만 Y1(왜도 0.36)·Y2(0.40)·X3(0.53)·X1(0.50)은 완만한 우측 비대칭을 보이는데, 이는 부하가 낮은 건물이 상대적으로 많고 일부 고부하 건물이 오른쪽 꼬리를 만드는 형태다. 변이계수(CV)로 비교하면 X7(0.57)·X8(0.55)의 상대적 퍼짐이 가장 크고, X1~X3(CV 0.13~0.14)는 값이 촘촘히 모여 있다 — 이는 시뮬레이션이 12가지 건물 형태 조합으로 생성되어 연속형처럼 보이는 변수도 실제로는 이산적인 값 몇 개가 반복되는 구조이기 때문이다. 첨도가 음수인 변수(X5 -2.01, X4 -1.78, X6 -1.36 등)가 많아 정규분포보다 납작하고 양 끝으로 퍼진 형태를 보인다. X6·X8은 정수 코드이지만 범주형 성격이 강한 변수이므로, 이 두 변수의 최빈값·왜도·첨도는 분포 모양이 아니라 범주 코드의 빈도로 해석했다.

변수	mean	median	std	CV	skew	kurtosis
X1	0.764	0.750	0.106	0.138	0.496	-0.707
X2	671.71	673.75	88.09	0.131	-0.125	-1.060
X3	318.50	318.50	43.63	0.137	0.533	0.117
X4	176.60	183.75	45.17	0.256	-0.163	-1.777
X5	5.250	5.250	1.751	0.334	0.000	-2.005

X6*	3.500	3.500	1.119	0.320	0.000	-1.361
X7	0.234	0.250	0.133	0.568	-0.060	-1.328
X8*	2.813	3.000	1.551	0.552	-0.089	-1.149
Y1	22.307	18.950	10.090	0.452	0.360	-1.246
Y2	24.588	22.080	9.513	0.387	0.396	-1.147

* X6, X8은 범주형 성격이 강한 변수 — 수치 자체보다 범주 빈도로 해석

1-3. 시각화로 확인한 구조적 특징

X1·X5·X6처럼 값의 종류가 제한된 변수는 히스토그램이 매끈한 종형이 아니라 계단식 막대 형태로 나타난다. 특히 X5(전체 높이)는 3.5와 7.0 두 값만 갖는 사실상 이진 변수이며, 이 때문에 Y1(난방 부하) 히스토그램도 뚜렷한 이봉 분포를 보인다 — 건물 층수(높이) 자체가 데이터를 두 그룹으로 나누는 구조적 요인임을 시각적으로 확인할 수 있다. 박스플롯 기준 뚜렷한 이상치는 거의 관측되지 않아 데이터 품질은 양호하다. 아래 그림은 이 구조적 특징을 가장 잘 보여주는 결과만 선별해 실었다.




그림 1. X5(전체 높이) 분포 — 3.5 / 7.0 두 값만 존재하는 사실상 이진 변수




그림 2. Y1(난방 부하) 분포 — X5의 이진 구조로 인한 이봉 분포




그림 3. X5 vs Y1 ($r=0.889$) — 두 수준으로 명확히 갈라지는 관계




그림 4. X8 vs Y1 ($r=0.087$) — "글레이징 유무(0 vs >0)"만의 미 있고 1~5 사이 차이는 미미

2. EDA 기반 유효 변수 선별

2-1. 상관관계 및 다중공선성 그룹

X1·X2·X4·X5는 서로 |상관계수| 0.83~0.99로 매우 강하게 얹혀 하나의 다중공선성 그룹(cluster_1)을 이룬다. 도메인적으로 자연스러운 결과인데, 이 데이터셋은 건물 부피를 고정한 채 형태만 바꿔 시뮬레이션했기 때문에 상대적 집약도(X1)·표면적(X2)·지붕면적(X4)·높이(X5)가 사실상 "건물이 얼마나 조밀하고 높은가"라는 하나의 축을 서로 다른 방식으로 표현한 값들이기 때문이다. X3(벽면적)은 이 그룹과 상관이 약해($|r| < 0.3$) 별도로 남았고, X7·X8도 서로 약한 상관(0.21)만 있어 독립적으로 유지된다. X6(방향)은 모든 변수와 상관계수가 사실상 0인데, 방위각이 순서 없는 명목형 범주이기 때문이며 계산 오류가 아니라 변수 성격상 당연한 결과다. 아래 히트맵은 이 다중공선성 구조가 데이터 전체에서 어떻게 나타나는지 한눈에 보여준다.




그림 5. 상관행렬 히트맵 (X1~X8, Y1, Y2)

2-2. 타겟과의 상관관계

변수	corr_Y1	corr_Y2
X5	0.889	0.896
X4	-0.862	-0.863
X2	-0.658	-0.673
X1	0.622	0.634
X3	0.456	0.427

X7	0.270	0.208
X8	0.087	0.051
X6	-0.003	0.014

Y1-Y2 상관계수: **0.976** — 두 타겟이 거의 동일한 패턴으로 움직인다.

2-3. 최종 변수 선택 원칙과 결과

상관관계 수치만으로 변수를 최종 선택하지 않는다는 원칙에 따라, 다중공선성 그룹(cluster_1: X1·X2·X4·X5) 내부에서는 타겟과의 |상관계수|가 가장 큰 **X5**를 대표로 남기고 나머지(X1·X2·X4)는 제외했다. 반면 그룹에 속하지 않은 X3·X6·X7·X8은 타겟 상관이 약해도(X6·X8) 임의로 제외하지 않고 그대로 후보에 남겼다. 그 결과 Y1·Y2 모두 최종적으로 [X3, X5, X6, X7, X8] 5개 변수가 선택되었다.

3. 모델링 결과 및 해석

선택된 5개 변수를 표준화(z-score)한 뒤, Y1·Y2 각각에 대해 독립적인 LinearRegression 모델을 학습했다 (train/test = 8:2, random_state 고정). 표준화를 적용해 서로 단위가 다른 변수들의 회귀계수 크기를 직접 비교할 수 있도록 했다.

3-1. 회귀계수 및 성능 지표

모델	선택 변수	R ²	RMSE	MAPE
Y1 (Heating Load)	X3, X5, X6, X7, X8	0.904	3.157	11.25%
Y2 (Cooling Load)	X3, X5, X6, X7, X8	0.882	3.314	9.48%

※ 모델 성능(R²/RMSE/MAPE)은 평가 대상이 아니며 참고 수치로만 기록

변수	표준화계수 (Y1)	표준화계수 (Y2)
X5 (전체 높이)	8.325	7.987
X7 (유리창 면적)	2.721	2.006
X3 (벽면적)	2.244	1.795
X8 (글레이징 분포)	0.332	0.056
X6 (방향)	-0.039	0.054

X5(건물 높이)의 계수가 가장 크고 부호가 양(+)이다 — 건물이 높을수록(층수가 많을수록) 난방·냉방 부하가 커진다는 것으로 도메인 상식과 부합한다. X7(유리창 면적)도 양의 계수인데, 유리는 벽체보다 단열 성능이 낮아 면적이 넓을수록 열 손실/유입이 커진다는 건축물리와 일치한다. X3(벽면적)도 양의 계수로 외피를 통한 열 교환이 늘어난다는 해석과 부합하며, X6·X8의 계수는 0에 가까워 실질적 영향력이 거의 없다 — 상관관계 분석 결과와 일치한다. Y1과 Y2는 선택 변수·계수 부호·영향력 순위가 거의 동일한데, 이는 Y1·Y2 상관계수가 0.976으로 극히 높았던 것과 일맥상통한다. select_features 단계에서 |상관계수| ≥ 0.8로 얹힌 X1·X2·X4·X5 그룹을 X5 하나로 줄였기 때문에, 최종 모델에 들어간 5개 변수 사이의 상관은 대부분 0에 가까워 다중공선성으로 인한 계수 불안정 위험은 낮다고 판단했다.

3-2. 잔차 진단 (회귀 가정 검토)

잔차(residual) 진단은 선형회귀 기본가정(선형성·등분산성·정규성)이 지켜지는지 확인하기 위한 것으로, 아래 두 그림은 Y1·Y2 모델 모두에서 공통적으로 나타난 핵심 패턴을 보여준다.




그림 6. Y1 잔차 진단




그림 7. Y2 잔차 진단

잔차 vs 예측값 플롯에서 예측값 약 20~27 구간이 비어 있는 두 개의 군집이 뚜렷하다. 이는 모델의 결함이라기 보다 X5가 사실상 이진 변수(3.5 / 7.0)라는 데이터 자체의 이산적 구조에서 비롯된 패턴이다. 각 군집 내부의 잔차는 대체로 0 주변에 분포하지만 완전히 무작위라고 보기는 어려워 등분산성 가정이 완벽히 충족된다고 말하기는 힘들다. 잔차 히스토그램은 대체로 0을 중심으로 종 모양이지만 오른쪽 꼬리에 작은 봉우리가 남아 있어 완전한 정규분포로 보기는 어렵다. 강의 범위상 별도의 정규성 검정은 수행하지 않고 히스토그램 형태로만 확인했다.

4. 종합 결론 및 분석 제약사항

- **에너지 효율에 가장 큰 영향을 미치는 변수:** X5(전체 높이)가 Y1·Y2 모두에서 가장 큰 표준화 계수와 가장 강한 타깃 상관(0.89~0.90)을 보여, 건물의 층수(높이)가 난방·냉방 부하를 가장 크게 좌우하는 특성으로 확인된다. 그 다음은 X7(유리창 면적)·X3(벽면적) 순이며, X6(방향)·X8(글레이징 분포)은 거의 영향이 없다.
- **X1·X2·X4의 역할:** 이 세 변수는 X5와 기하학적으로 강하게 얽혀 있어(다중공선성) 최종 모델에는 직접 포함하지 않았지만, "건물이 얼마나 조밀하고 높은가"라는 동일한 특성을 X5가 대표하는 것으로 해석할 수 있다. 즉 배제된 것이 아니라 X5를 통해 간접적으로 반영되었다.
- **Y1과 Y2의 결론 비교:** 선택된 변수·계수 부호·영향력 순위가 사실상 동일하다. Y1-Y2 상관계수가 0.976으로 매우 높았던 결과와 일치하며, 난방과 냉방 부하가 "건물 형태(높이·조밀도)"와 "외피를 통한 열 손실/유입(벽·유리창 면적)"이라는 공통된 물리적 메커니즘의 영향을 받기 때문으로 해석된다.

분석 제약사항

- 상관관계만으로 최종 변수를 선별하지 않았다 — 다중공선성 그룹 내부의 대표 변수 선정에만 상관계수를 참고했고, 그룹에 속하지 않은 변수는 타깃 상관이 약해도 임의로 제외하지 않았다.
- VIF, 단계적 선택법, ANOVA, Tukey HSD 등 강의에서 다루지 않은 기법은 사용하지 않고, 상관계수 임계값 기반 그룹핑 등 강의 범위 내 개념만으로 다중공선성을 다뤘다.
- X6·X8은 정수 코드지만 범주형 성격이 강한 변수를 그대로 선형회귀에 투입한 한계가 있다 — 예를 들어 X8은 "0(없음) vs 1~5(있음)"의 계단형 패턴을 보였는데, 선형회귀는 이를 하나의 기울기로만 표현하므로 실제 관계를 완전히 담아내지 못한다(원-핫 인코딩 등은 강의 범위를 벗어나 다루지 않았다).
- X5가 사실상 이진 변수라는 데이터의 이산적 특성 때문에 잔차가 두 개의 군집으로 나뉘어, 등분산성·정규성 가정이 완벽하게 충족되지는 않는다.
- 모델 성능(R^2 /RMSE/MAPE)은 참고 수치로만 기록했으며, 평가의 핵심은 회귀 기본가정을 고려해 변수를 선별하고 그 결과를 통계적으로 해석하는 데 있었다.

팀 구성 / 담당

① 기술통계 — 박연제 · ② 시각화 — 손수경 · ③ 상관관계·다중공선성 — 이설현 · ④ 변수선택·회귀모델(Y1/Y2 각 1인) — 이정인 & 김근홍 · 통합/보고서 — 박연제