

종합실습 2 실행결과 정리

실행결과 화면

터미널

```
Data file already exists. Skipping download.
Comparing loading performance...
Pandas loading time: 0.3854 sec
Polars loading time: 0.2589 sec
Polars is 1.5x faster.

Data cleaning finished. Total rows: 3,084,453
Cleaned data saved at: /Users/yeonjep/Desktop/SKALA/SKALA_4/python-data-project-v1/src/../data/cleaned_taxi.parquet
[2] 정제된 데이터 로딩
로딩된 데이터: 3,084,453행

[2] 시각화 생성
Seaborn 분포 차트 저장 완료: /Users/yeonjep/Desktop/SKALA/SKALA_4/python-data-project-v1/output/seaborn_distribution.png
Plotly 그룹비교 차트 저장 완료: /Users/yeonjep/Desktop/SKALA/SKALA_4/python-data-project-v1/output/plotly_group_comparison.html

=====
[실습 3번] 통계 분석 및 가설 검정 결과 (phase3.py)
=====

1. 기술통계량 산출 (요금 및 이동 거리)

[Pandas] 요약 기술통계:
      fare_amount  trip_distance
count  3.084453e+06  3.084453e+06
mean    2.024879e+01  3.427613e+00
std     1.876875e+01  6.219623e+00
min     1.000000e-02  1.000000e-02
25%     9.300000e+00  1.000000e+00
50%     1.420000e+01  1.710000e+00
75%     2.330000e+01  3.400000e+00
max     5.525990e+03  5.071010e+03

[Polars] 주요 통계량:
shape: (1, 6)



| fare_mean | fare_std  | fare_median | distance_mean | distance_std | distance_median |
|-----------|-----------|-------------|---------------|--------------|-----------------|
| f64       | f64       | f64         | f64           | f64          | f64             |
| 20.248791 | 18.768755 | 14.2        | 3.427613      | 6.219623     | 1.71            |



=====

2. 피어슨 상관계수 계산 (이동 거리 vs 요금)
[Pandas] 상관계수: 0.6330
[Polars] 상관계수: 0.6330
```

```

3. 독립표본 t-test 분석 (단거리 vs 장거리 요금 차이)
- 귀무가설 (H0): 단거리 (2마일 미만)와 장거리 (2마일 이상) 그룹의 평균 요금은 같다.
- 대립가설 (H1): 두 그룹의 평균 요금은 통계적으로 유의미한 차이가 있다.

- 단거리 그룹 크기: 1,744,816개 (평균 요금: $10.91)
- 장거리 그룹 크기: 1,339,637개 (평균 요금: $32.41)

- t-통계량 (t-statistic): -1105.4286
- 유의확률 (p-value): 0.0000e+00

[해석 결과]
p-value가 0.0000e+00로 유의수준 0.05보다 매우 작으므로 귀무가설 (H0)을 기각합니다.
=> 즉, 이동 거리 (단거리 vs 장거리)에 따른 요금 평균 차이는 통계적으로 매우 유의미합니다.

=====
[4] ML Pipeline 평가 결과 (payment_type 분류)
=====
학습 샘플 수 : 2,438,228
검증 샘플 수 : 609,557
정확도 (Accuracy) : 0.6400
F1-score : 0.7624
정밀도 (Precision): 0.9090
재현율 (Recall) : 0.6565

혼동행렬 (confusion matrix):
[[352056 184218]
 [ 35225 38058]]

=====
분류 리포트 :
precision    recall  f1-score   support

   card(1)      0.91      0.66      0.76   536274
   cash(2)      0.17      0.52      0.26    73283

 accuracy      0.54      0.59      0.51   609557
macro avg      0.54      0.59      0.51   609557
weighted avg   0.82      0.64      0.70   609557

[저장 완료] 모델이 'model.joblib' 에 저장되었습니다.
[저장 완료] 특성 중요도 그래프가 'feature_importance.png' 에 저장되었습니다.

상위 특성 중요도 (Top 10):
feature importance
num_fare_amount    0.335878
num_trip_distance  0.265276
num_trip_duration_min 0.249955
num_pickup_hour    0.103830
num_passenger_count 0.045062
2026-07-16 19:04:05 | INFO | Starting report generation
2026-07-16 19:04:05 | INFO | Outputs directory: /Users/yeonjep/Desktop/SKALA/SKALA_4/python-data-project-v1/output
2026-07-16 19:04:05 | INFO | Template path: /Users/yeonjep/Desktop/SKALA/SKALA_4/python-data-project-v1/src/report/templates/report_template.md

=====
2026-07-16 19:04:06 | INFO | Merged runtime results for section: data
2026-07-16 19:04:06 | INFO | Merged runtime results for section: stats
2026-07-16 19:04:06 | INFO | Merged runtime results for section: ml
2026-07-16 19:04:06 | INFO | Report written: /Users/yeonjep/Desktop/SKALA/SKALA_4/python-data-project-v1/report.md

```

분석리포트(report.md)

분석 리포트

생성 시각: 2026-07-16 19:04:06

1. 데이터 준비

- 데이터셋: NYC Yellow Taxi Trip Data 2026-05
- 행/열 수: 3084453 / 7
- 결측치 처리 및 현황: `복합 값 - 상세 결과 참고`
- 중복 처리 및 현황: `복합 값 - 상세 결과 참고`
- Pandas / Polars 비교: phase1.py에서 Pandas/Polars 로딩 시간을 비교하여 콘솔에 출력

결측치 상세

- total_missing_cells: 0
- columns_with_missing: 0

중복 상세

- duplicate_rows: 0
- action: drop_duplicates 및 dropna 적용

2. 기본 EDA 및 시각화

주요 관찰

미제공


예상 시각화 산출물

- `output/seaborn_distribution.png`
- `output/plotly_group_comparison.html`

확인된 시각화 산출물


- 이동 거리 분포 PNG: `output/seaborn_distribution.png`
- 시간대별 평균 요금 HTML: `output/plotly_group_comparison.html`

Seaborn 이동 거리 분포



Plotly 시간대별 평균 요금

Plotly 인터랙티브 차트



3. 통계 분석

기술통계: 평균, 표준편차, 분위수

미제공

변수 간 상관관계수

- trip_distance_vs_fare_amount: 0.632962

t-test

- p-value: 0
- 해석: p-value가 0.0000e+00로 유의수준 0.05보다 매우 작으므로 귀무가설(H_0)을 기각합니다. => 즉, 이동 거리(단거리 vs 장거리)에 따른 요금 평균 차이는 통계적으로 매우 유의미합니다.

t-test 상세 결과

- t_statistic: -1105.43
- short_mean: 10.9145
- long_mean: 32.4063

4. ML Pipeline

- 작업 유형: classification
- 사용 모델: RandomForestClassifier
- 저장된 모델 경로: 미제공

Pipeline 구성

- preprocessing: ColumnTransformer: numeric imputer/scaler + categorical imputer/one-hot
- model: RandomForestClassifier
- target: payment_type

평가 지표

- accuracy: 0.639996
- f1: 0.762393
- precision: 0.909045
- recall: 0.656485
- n_train: 2438228
- n_test: 609557

confusion_matrix

- [352056, 184218]
- [35225, 38058]

분류 리포트

	precision	recall	f1-score	support
card(1)	0.91	0.66	0.76	536274
cash(2)	0.17	0.52	0.26	73283
accuracy			0.64	609557
macro avg	0.54	0.59	0.51	609557
weighted avg	0.82	0.64	0.70	609557

상위 특성 중요도

특성	중요도
num__fare_amount	0.335878
num__trip_distance	0.265276
num__trip_duration_min	0.249955
num__pickup_hour	0.103830
num__passenger_count	0.045062

5. 자동화 및 재현성

- 입력 디렉터리: `output`
- 리포트 파일: `report.md`
- 로그 파일: `logs/report_generation.log`
- 실행 명령어: `python3 src/main.py`

코드 분석 및 개인 의견

[강점]

- 팀원별로 정제된 데이터(cleaned_taxi.parquet)를 공통 입력으로 사용해 독립적으로 작업하는 구조로, 역할 중복 없이 단계별 연결이 자연스러움
- 예외처리와 함수 단위 분리가 잘 되어 있어 유지보수성이 높음

[개선점]

- phase4: 위치 정보 컬럼(PULocationID 등)이 정제 단계에서 제외되어 범주형 특성 없이 수치형 변수만으로 학습 진행 → 결제수단 예측 정확도를 제한하

는 요인으로 판단됨

- phase2: 초기에는 이동거리 이상치로 히스토그램 bin이 왜곡되는 문제가 있었으나, 상위 1% 값 제외 및 비율(%) 기준 전환으로 해석 가능한 결과로 개선함
- 파일 경로 처리 방식이 phase마다 os.path와 pathlib로 혼용되어 있어 통일 필요